Pontificia Universidad Católica de Chile
Instituto de Ingeniería Matemática y Computacional 2026-2

IMT2220

Cálculo para Ciencia de Datos

Tarea Computacional

Grupo 3

INTEGRANTES
Damián Bravo
Carolina Lobos
Felipe López
Matías Sepúlveda

Profesor
Eduardo Cerpa
eduardo.cerpa@uc.cl

Ayudante
Kevin Cardemil
kevin.cardemil@uc.cl

PROBLEMA 1

Reconstrucción de una imagen

(a) Mínimos cuadrados

i. **Gradiente y matriz Hessiana de J_0.**

Dada $J_0(x) = \|Ax - b\|_2^2$, Descomponemos la Jacobiana como una composición de dos funciones:

$$r(x) = Ax - b \qquad \text{(residuo)}$$
$$q(r) = \|r\|_2^2 = r^T r \qquad \text{(norma euclídea)}$$

Aplicamos regla de la cadena a las funciones:

$$J_r(x) = A$$
$$\nabla q(r) = 2r$$

Derivamos nuevamente el gradiente, obteniendo de esta forma la matriz Hessiana:

$$H_{J_0}(x) = 2A^T A$$

Buscamos los puntos críticos:

$$\nabla J_0(x) = 0$$
$$2A^T(Ax - b) = 0 \iff A^T Ax = A^T b \quad \text{(ecuaciones normales)}$$

ii. **H_{J_0} es semidefinida positiva y todo punto crítico es un mínimo global.**

Para cualquier $h \in \mathbb{R}^n$:

$$h^T H_{J_0} h = 2h^T A^T Ah = 2\|Ah\|_2^2 \geq 0$$

Luego, $H_{J_0} = 2A^T A$ es semidefinida positiva. J_0 es un polinomio de grado 2, Por lo que su aproximación de Taylor de 2° orden es exacta, de forma que:

$$J_0(x_0 + h) = J_0(x_0) + \nabla J_0(x_0)^T h + \frac{1}{2} h^T H_{J_0} h$$

En un punto crítico x_0:

$$J_0(x_0 + h) = J_0(x_0) + \frac{1}{2} \cdot 2\|Ah\|_2^2 = J_0(x_0) + \|Ah\|_2^2 \geq J_0(x_0)$$

para todo h. Por lo tanto, todo punto crítico de J_0 es mínimo global.

iii. **Unicidad o infinitos minimizadores.**

Sea μ_i el i-ésimo valor propio de $A^T A$ y v_i su vector propio ortonormal, se deben considerar dos casos:

i. Caso 1: Todos los $\mu_i > 0$
$A^T A$ es definida positiva, por lo que es invertible y las ecuaciones normales $A^T Ax = A^T b$ tienen una única solución:

$$x_0 = (A^T A)^{-1} A^T b \tag{1}$$

ii. Caso 2: Existe $\mu_j = 0$
Entonces, hay $v_j \neq 0$ que cumplan $A^T Av_j = 0$, es decir, $\|Av_j\|_2^2 = 0$ y se sigue que $Av_j = 0$. Si x_0 es un minimizador, también lo es $x_0 + tv_j$ para todo $t \in \mathbb{R}$, ya que:

$$J_0(x_0 + tv_j) = J_0(x_0) + t^2\|Av_j\|_2^2 = J_0(x_0)$$

Habiendo así infinitos minimizadores.

(b) Reconstrucción

i. **Implementación.**

Tenemos que:

i. $\|x_0\|_2 = 1300698.2458$

ii. $\max_i |x_{0,i}| = 82816.1310$

iii. $\|Ax_0 - b\|_2 = 2.01e - 11$

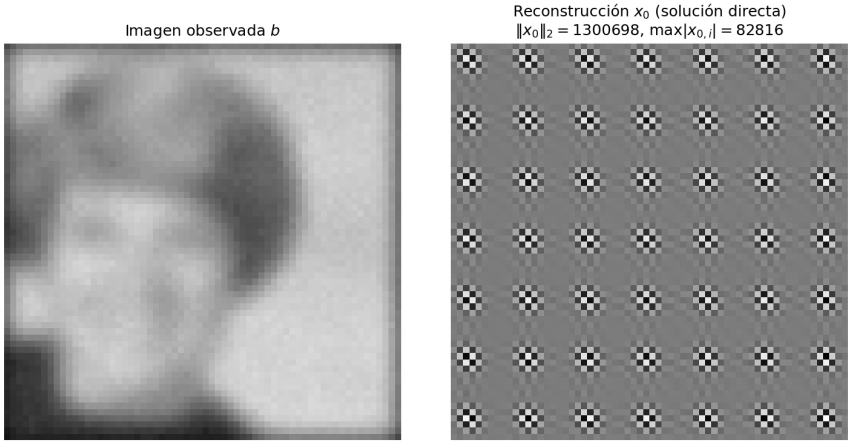


Figura 1: Imagen observada b e imagen reconstruida x_0.

Es notorio que x_0 no corresponde a una imagen válida. En primer lugar, x_0 no se parece a b, esto porque sus valores se pasan mucho del rango[0, 1], luego, el resultado no parece una imagen. Para que x_0 fuese válida, se debe cumplir que la norma sea menor o igual a $\sqrt{n} = 64$.

ii. **Explicación.** Sabemos que $A^T A\, x_0 = A^T b$, considerando que $b = Ax^* + \eta$, reemplazamos en la ecuación:

$$A^T b = A^T(Ax^* + \eta) = A^T A\, x^* + A^T \eta$$
$$A^T A\, x_0 = A^T A\, x^* + A^T \eta$$
$$A^T A\,(x_0 - x^*) = A^T \eta$$

Ahora, hacemos producto punto a ambos lados de la igualdad con v_i:

$$\langle A^T A\,(x_0 - x^*),\ v_i\rangle = \langle A^T\eta,\ v_i\rangle$$

Sabiendo que $A^T A$ es simétrica y v_i un vector propio:

$$\langle x_0 - x^*,\ A^T A\,v_i\rangle = \langle x_0 - x^*,\ \mu_i v_i\rangle = \mu_i\,\langle x_0 - x^*,\ v_i\rangle$$

Simplificamos:

$$\langle A^T\eta,\ v_i\rangle = \langle \eta,\ Av_i\rangle$$
$$\mu_i\,\langle x_0 - x^*,\ v_i\rangle = \langle \eta,\ Av_i\rangle$$

y dado que $\mu_i > 0$:

$$\langle x_0 - x^*, v_i\rangle = \frac{\langle \eta, Av_i\rangle}{\mu_i}.$$

Por Cauchy–Schwarz y $\|Av_i\|_2 = \sqrt{\mu_i}$:

$$|\langle x_0 - x^*, v_i\rangle| \le \frac{\|\eta\|_2}{\sqrt{\mu_i}}$$

Dada la igualdad $\langle x_0 - x^*, v_i\rangle = \frac{\langle \eta, Av_i\rangle}{\mu_i}.$, $\frac{\langle \eta, Av_i\rangle}{\mu_i}$. depende solamente del valor de η, si ocurre que $\eta = 0$, obtendríamos $\langle \eta, Av_i\rangle = 0$, ya que el lado izquierdo de la igualdad corresponde al error de la reconstrucción en la dirección del vector v_i, el error sería cero sin importar la dirección que se elija; ello implica que $x_0 = x^*$ exacto.

Un ruido pequeño da un error muy grande pues para $\mu_{\min} \approx 2 \cdot 10^{-16}$ tendremos un error de amplificación $1/\sqrt{\mu_{\min}} \approx 7 \cdot 10^7$, haciendo que el error en tal dirección llegue a $\|\eta\|/\sqrt{\mu_{\min}} \approx 0.64 \cdot 7 \cdot 10^7 \approx 4.5 \cdot 10^7$, siendo que el ruido de norma debería cumplir que $\sqrt{n} = 64$, pasándose de este valor por mucho. Además, tenemos 1858 direcciones que cumplen $\mu_i < 10^{-6}$, cada una con una amplificación $1/\sqrt{\mu_i} > 10^3$, lo que acumula un error enorme sobre la solución.

(c) Regularización de Tikhonov

i. **Gradiente, Hessiana y único minimizador global.**

Calculamos el gradiente de $J_\lambda(x)$:

$$\nabla J_\lambda(x) = 2A^T(Ax - b) + 2\lambda x = 2(A^T A + \lambda I)x - 2A^T b,$$

Calculamos la Hessiana de $J_\lambda(x)$:

$$H_{J_\lambda}(x) = 2(A^T A + \lambda I)$$

Como $A^T A\,v_i = \mu_i v_i$, tenemos que $(A^T A + \lambda I)v_i = (\mu_i + \lambda)v_i$, siendo $2(\mu_i + \lambda)$ los valores propios de H_{J_λ}. Como $\mu_i \ge 0$ y $\lambda > 0$:

$$2(\mu_i + \lambda) \ge 2\lambda > 0 \quad \forall i,$$

por lo tanto, H_{J_λ} es definida positiva. de esta forma se garantiza que hay un minimizador global único. Igualamos el gradiente a 0:

$$2(A^T A + \lambda I)x = 2A^T b \implies x_\lambda = (A^T A + \lambda I)^{-1} A^T b$$

ii. **Descomposición de $\langle x_\lambda, v_i\rangle$ y cota del aporte del ruido.**

Proyectamos x_λ sobre v_i (utilizando la igualdad$A^T b = A^T A x^* + A^T \eta$ y $A^T A v_i = \mu_i v_i$):

$$\langle x_\lambda, v_i\rangle = \frac{\mu_i}{\mu_i + \lambda}\langle x^*, v_i\rangle + \frac{\langle Av_i, \eta\rangle}{\mu_i + \lambda}$$

Aplicamos Cauchy-Schwarz y $\|Av_i\|_2 = \sqrt{\mu_i}$:

$$\left|\frac{\langle Av_i, \eta\rangle}{\mu_i + \lambda}\right| \leq \frac{\sqrt{\mu_i}}{\mu_i + \lambda}\|\eta\|_2 \leq \frac{\|\eta\|_2}{2\sqrt{\lambda}}$$

usando la indicación $\mu + \lambda \geq 2\sqrt{\mu\lambda}$, luego $\frac{\sqrt{\mu}}{\mu+\lambda} \leq \frac{1}{2\sqrt{\lambda}}$.

El primer término $\frac{\mu_i}{\mu_i+\lambda}\langle x^*, v_i\rangle$ es la parte recuperada de la imagen, atenuada por el factor $\frac{\mu_i}{\mu_i+\lambda}$. El segundo es el aporte del ruido, que es acotado de manera uniforme por $\frac{\|\eta\|_2}{2\sqrt{\lambda}}$ sin importar que tan pequeño sea μ_i. Tikhonov elimina la amplificación catastrófica del ruido al reemplazar el μ_i del denominador por $\mu_i + \lambda \geq \lambda$.

iii. **Interpretación.**

Según el factor $\frac{\mu_i}{\mu_i+\lambda}$:

- Si $\mu_i \gg \lambda$, el factor es ≈ 1; recuperamos casi totalmente dicha componente de x^*, lo que hace que el ruido en esa dirección sea pequeño
- Si $\mu_i \ll \lambda$, el factor es ≈ 0; la componente se atenúa pero se suprime el ruido que ahí se amplificaba.
- Si λ es muy pequeño, $x_\lambda \approx x_0$; se recuperan la totalidad de las componentes, pero los μ_i pequeños siguen amplificando mucho el ruido.
- Si λ es muy grande, todas las componentes se suprimen ($x_\lambda \approx 0$) y el residuo $\|Ax_\lambda - b\|_2$ crece. Una alta regularización destruye la imagen.

iv. **Implementación.**

	$\|x\|_2$	$\|Ax - b\|_2$
x_0	1300698.2458	2.01e-11
$\lambda = 10^{-3.5}$	44.3611	0.5519
$\lambda = 10^{-2.5}$	43.4224	0.6156
$\lambda = 1$	20.7048	21.5357

Tabla 1: Norma y residuo de cada reconstrucción.



Figura 2: Imagen observada b y sus reconstrucciones.

Utilizamos $\delta = 0.64$ como referencia para el residuo, mirando la tabla:

- $\lambda = 10^{-3.5}$: residuo 0.5519, empieza a ajustarse el ruido.
- $\lambda = 10^{-2.5}$: residuo $0.6156 \approx \delta$. Se ajustan los datos no más allá del nivel del ruido. La figura más clara entre las reconstrucciones.
- $\lambda = 1$: residuo $21.54 \gg \delta$. Está muy por encima de δ, además la norma es muy pequeña. De esta manera, se destruye la imagen.

Un λ muy pequeño, deja que las direcciones con μ_i pequeño amplifiquen el ruido (como en x_0), y un λ muy grande atenúa la imagen verdadera. El valor $\lambda = 10^{-2.5}$ equilibra ambos efectos.

(d) Píxeles dañados

Reconstruimos la imagen a partir de $\tilde{b}$ usando Tikhonov con $\lambda = 10^{-2.5}$. Obtenemos $\|x_{\text{def}}\|_2 = 52.06$ y $\|Ax_{\text{def}} - \tilde{b}\|_2 = 10.32$.

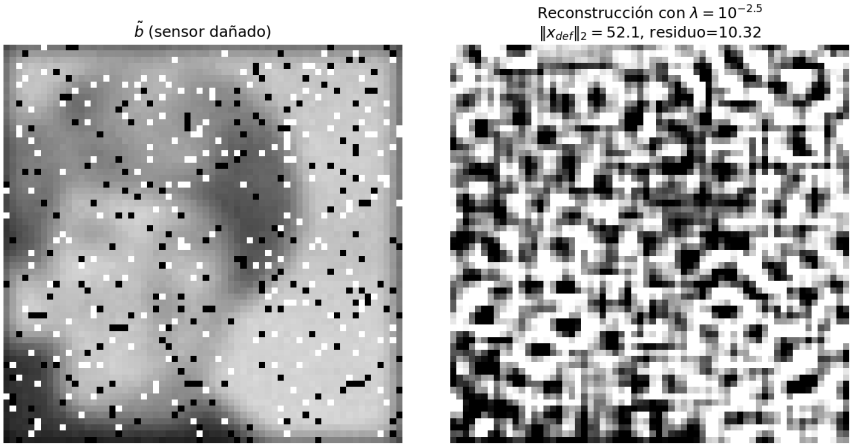


Figura 3: Imagen observada $\tilde{b}$ e imagen reconstruida con $\lambda = 10^{-2.5}$.

i. $\tilde{\eta} = \eta + (\tilde{b} - b)$ **e interpretación de sus sumandos.**

Ya que $\tilde{b} = Ax^* + \tilde{\eta}$ y sabiendo que $b = Ax^* + \eta$. Despejamos $\tilde{\eta}$:

$$\tilde{\eta} = \tilde{b} - Ax^* = (\tilde{b} - b) + (b - Ax^*) = (\tilde{b} - b) + \eta,$$

es decir $\tilde{\eta} = \eta + (\tilde{b} - b)$.

- η: el ruido del sensor, con $\|\eta\|_2 \approx \delta = 0.64$. Es pequeño.
- $\tilde{b} - b$: el ruido impulsivo de los píxeles dañados. Un píxel dañado registra 0 o 1 sin importar su valor verdadero, lo que genera errores del orden de 1 en cada píxel afectado.

ii. **$\|\tilde{b} - b\|_2$ y comparación de $\|\tilde{\eta}\|_2$ con δ.**

Calculamos la diferencia entre la observación dañada y la limpia:

$$\|\tilde{b} - b\|_2 = 11.20,$$

que es unas 17.5 veces mayor que $\delta = 0.64$. Además se estima que hay 435 píxeles dañados de los 4096 (un 10.6%). Se sigue que:

$$\|\tilde{\eta}\|_2 \approx \|\tilde{b} - b\|_2 = 11.20 \gg \delta = 0.64.$$

iii. **¿Por qué fracasa la reconstrucción? ¿Bastaría con aumentar λ?**

Usamos la cota del (c) ii. con $\tilde{\eta}$ en lugar de η:

$$\left| \frac{\langle Av_i, \tilde{\eta} \rangle}{\mu_i + \lambda} \right| \leq \frac{\|\tilde{\eta}\|_2}{2\sqrt{\lambda}}.$$

Como $\|\tilde{\eta}\|_2 \approx 11.2$ es 17.5 veces mayor que en el caso limpio, a $\lambda = 10^{-2.5}$ la cota del aporte del ruido es 17.5 veces más grande.

Aumentar λ no lo arregla, por dos razones:

i. Por la cota. Para recuperar la cota del caso sin daño, deberíamos multiplicar λ por $(11.2/0.64)^2 \approx 306$, llegando a $\lambda \approx 1$. Pero con $\lambda \approx 1$ el factor de señal $\frac{\mu_i}{\mu_i + \lambda}$ se vuelve pequeño y la imagen queda difuminada: es justo el caso $\lambda = 1$ de (c) iv., con residuo ≈ 21.5.

ii. Por el barrido numérico. Para $\lambda \geq 10^{-4}$ el residuo contra $\tilde{b}$ nunca baja de ≈ 9, muy por encima de δ. Y si reducimos λ para ajustar mejor $\tilde{b}$, la norma de x_λ explota (llega a ≈ 295 en $\lambda = 10^{-4}$, cuando una imagen válida tiene norma ≤ 64).

La causa de fondo es que el ruido impulsivo no es pequeño, cada píxel dañado se desvía entre 0.13 y 0.86, y afecta a cerca del 10% de las lecturas. Un único λ en Tikhonov no puede absorberlo.

(Bonus) Mínimos cuadrados ponderados

Si conocemos qué píxeles están dañados, podemos ignorarlos. Sea $w \in \{0, 1\}^n$ con $w_p = 0$ si el píxel p está dañado y $w_p = 1$ si no lo está, tomamos $W = \text{diag}(w)$ y minimizamos:

$$J_W(x) = (Ax - \tilde{b})^T W (Ax - \tilde{b}) + \lambda \|x\|_2^2.$$

Usando que W es diagonal, y por tanto simétrica, calculamos el gradiente:

$$\nabla J_W(x) = 2A^T W(Ax - \tilde{b}) + 2\lambda x = 2(A^T W A + \lambda I)x - 2A^T W \tilde{b},$$

El sistema a resolver es:

$$(A^T W A + \lambda I)\, x = A^T W \tilde{b}.$$

Para construir w identificamos los píxeles dañados, aprovechando que debido a el ruido del sensor, una observación limpia no tendrá valores exactamente iguales a 0 ni a 1. Determinando cada píxel p dañado con $\tilde{b}_p \in \{0, 1\}$ exacto y le asignamos $w_p = 0$. Teniendo 435 píxeles dañados de los 4096 (un 10.6%).

Resuelvemos el sistema con $\lambda = 10^{-2.5}$, obteniendo

$$\|x_W\|_2 = 43.39, \qquad \|Ax_W - b\|_2 = 0.628 \approx \delta = 0.64.$$

La norma queda en el rango válido de una imagen ($\leq \sqrt{n} = 64$) y el residuo contra la observación limpia b alcanza el nivel del ruido. Comparando:

- reconstrucción ponderada (bonus): difiere en un 1.5% de la reconstrucción limpia;
- Tikhonov sin ponderar: difiere en un 70.1%.

PROBLEMA 2

Red neuronal con dos capas ocultas

(a) Derivada de la sigmoide

La función sigmoide es $\sigma(t) = \dfrac{1}{1+e^{-t}}$.

Derivamos aplicando regla del cociente, con $u = 1$ y $v = 1 + e^{-t}$:

$$\sigma'(t) = \frac{0 \cdot (1+e^{-t}) - 1 \cdot (-e^{-t})}{(1+e^{-t})^2} = \frac{e^{-t}}{(1+e^{-t})^2}.$$

Factorizamos:

$$\sigma'(t) = \frac{1}{1+e^{-t}} \cdot \frac{e^{-t}}{1+e^{-t}} = \frac{1}{1+e^{-t}} \cdot \frac{(1+e^{-t})-1}{1+e^{-t}} = \sigma(t)\,(1-\sigma(t)).$$

Sea $s = \sigma(t) \in (0,1)$ para todo t, tenemos $s \in (0,1)$, entonces:

$$\sigma'(t) = s(1-s)$$

Se tiene que $\sigma'(t) > 0$ y por la desigualdad AM-GM

$$s(1-s) \leq \left(\frac{s+(1-s)}{2}\right)^2 = \frac{1}{4},$$

Resulta en igualdad si y sólo si $s = 1-s$, es decir $s = \frac{1}{2}$,que ocurre cuando $\sigma(t) = \frac{1}{2}$ con $t = 0$. Por lo tanto

$$0 < \sigma'(t) \leq \frac{1}{4} \quad \forall\, t \in \mathbb{R},$$

y alcanzamos el máximo en $t = 0$.

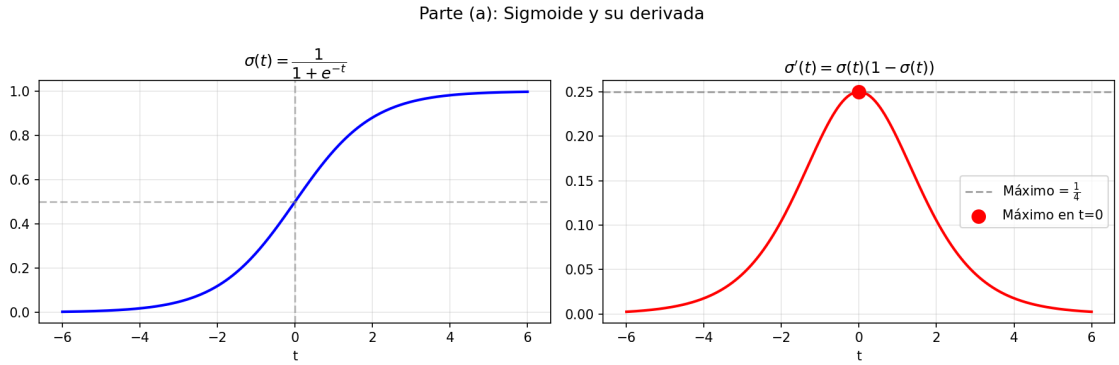


Figura 4: La sigmoide $\sigma(t)$ y su derivada $\sigma'(t)$, con máximo $1/4$ en $t = 0$.

(b) Función de pérdida y su gradiente

La red tiene parámetros $\theta = (a_1, b_1, a_2, b_2, v, c) \in \mathbb{R}^6$. Para cada par (x_i, y_i) definimos:

$$z_{1,i} = a_1 x_i + b_1, \quad h_{1,i} = \sigma(z_{1,i})$$

$$z_{2,i} = a_2 h_{1,i} + b_2, \quad h_{2,i} = \sigma(z_{2,i})$$

$$\hat{y}_i = c + v h_{2,i}, \quad e_i = \hat{y}_i - y_i$$

La función de pérdida es:

$$J(\theta) = \frac{1}{2N} \sum_{i=1}^{N} e_i^2 = \frac{1}{N} \sum_{i=1}^{N} L_i, \qquad L_i = \tfrac{1}{2} e_i^2.$$

Usamos el grafo computacional para cada i. La pérdida individual es $L_i = \frac{1}{2} e_i^2$. A partir de Como $\hat{y}_i = c + v\, h_{2,i}$ se sigue:

(a) Derivada respecto a c: c afecta $\hat{y}_i$ directamente:

$$\frac{\partial L_i}{\partial c} = e_i \cdot 1 = e_i$$

(b) Derivada respecto a v: v afecta $\hat{y}_i$ a través de $v h_{2,i}$:

$$\frac{\partial L_i}{\partial v} = e_i \cdot h_{2,i}$$

(c) Derivada respecto a b_2: $b_2 \to z_{2,i} \to h_{2,i} \to \hat{y}_i \to L_i$:

$$\delta_{2,i} := \frac{\partial L_i}{\partial z_{2,i}} = e_i \cdot v \cdot \sigma'(z_{2,i})$$

$$\frac{\partial L_i}{\partial b_2} = \delta_{2,i} \cdot 1 = \delta_{2,i}$$

(d) Derivada respecto a a_2: $a_2 \to z_{2,i} \to \ldots \to L_i$:

$$\frac{\partial L_i}{\partial a_2} = \delta_{2,i} \cdot h_{1,i}$$

(e) Propagamos hacia atrás a través de la primera capa:

$$\delta_{1,i} := \frac{\partial L_i}{\partial z_{1,i}} = \delta_{2,i} \cdot a_2 \cdot \sigma'(z_{1,i})$$

(f) Derivada respecto a b_1: $b_1 \to z_{1,i} \to \ldots \to L_i$:

$$\frac{\partial L_i}{\partial b_1} = \delta_{1,i}$$

(g) Derivada respecto a a_1: $a_1 \to z_{1,i} \to \ldots \to L_i$:

$$\frac{\partial L_i}{\partial a_1} = \delta_{1,i} \cdot x_i$$

Gradiente de J (promedio sobre todos los datos):

$$\nabla_\theta J(\theta) = \frac{1}{N} \sum_{i=1}^{N} \begin{pmatrix} \delta_{1,i} x_i \\ \delta_{1,i} \\ \delta_{2,i} h_{1,i} \\ \delta_{2,i} \\ e_i h_{2,i} \\ e_i \end{pmatrix}$$

donde $\delta_{2,i} = e_i v \sigma'(z_{2,i})$ y $\delta_{1,i} = \delta_{2,i} a_2 \sigma'(z_{1,i})$.

(c) Implementación y verificación del gradiente

Parámetro	Fórmula de (b)	D_j	Diferencia
a_1	0.0082217484	0.0082217484	$1.00e-11$
b_1	0.0362284884	0.0362284885	$3.13e-11$
a_2	0.2612270505	0.2612270505	$9.50e-12$
b_2	0.3731255768	0.3731255768	$1.81e-11$
v	−1.4566714937	−1.4566714936	$1.45e-11$
c	−2.3208098450	−2.3208098450	$1.38e-11$

Tabla 2: Gradiente en θ_0: fórmulas de (b) y diferencias centradas.

El error máximo fue

$$E = \max_{j=1,\ldots,6} \left| \frac{\partial J}{\partial \theta^{(j)}}(\theta_0) - D_j \right| = 3.13 \times 10^{-11},$$

del orden de $h^2 = 10^{-10}$.

(d) Descenso del gradiente

Calculamos el descenso del gradiente en 20.000 iteraciones, con paso fijo $\alpha = 1$. La fórmula es:

$$\theta_{k+1} = \theta_k - \alpha \, \nabla J(\theta_k),$$

.

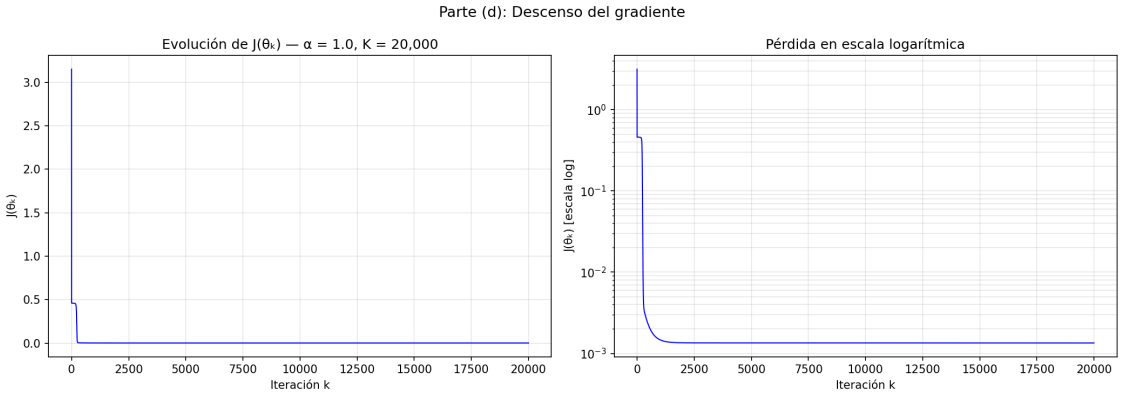


Figura 5: Evolución de la pérdida $J(\theta_k)$ con $\alpha = 1$ y $K = 20\,000$, en escala lineal (izquierda) y logarítmica (derecha).

La curva de J tiene tres fases, las analizaremos:

(a) Caída rápida en las primeras ~ 10 iteraciones, desde $J(\theta_0) = 3.15$ hasta ≈ 0.46.

(b) Meseta en $J \approx 0.46$, que coincide con $\frac{1}{2}\mathrm{Var}(y) = 0.4597$. En esta fase, la red predice esencialmente la media constante $\bar{y} \approx 1.20$ y todavía no usa la variación de x; la meseta se extiende desde $k \approx 10$ hasta algún punto entre $k \approx 100$ y $k \approx 1000$.

(c) Salta hacia $J \approx 0.0015$ y luego converge lentamente hasta $J(\theta_{20000}) = 0.001344$.

El descenso del gradiente termina en una zona donde J ya casi no baja, pero la meseta muestra que pasa por un punto de J muy alto antes de encontrar la pendiente útil.

(e) Parámetros encontrados

Tras las $20\,000$ iteraciones se consiguen los parámetros

$$\theta_{20000} = (a_1, b_1, a_2, b_2, v, c) = (-4.9195,\ -1.0525,\ -3.5427,\ 1.6546,\ 3.4116,\ -0.6558),$$

y de pérdida final

$$J(\theta_{20000}) = 0.001344.$$

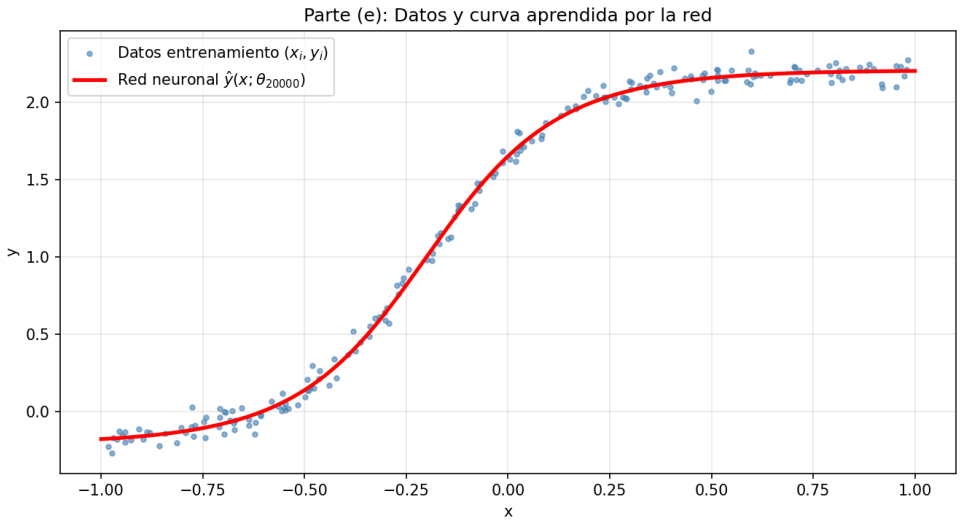


Figura 6: Datos de entrenamiento y curva aprendida $\hat{y}(x;\theta_{20000})$ en $[-1, 1]$.

(f) Sensibilidad del entrenamiento

i. Tamaño del paso.

Partiendo del mismo θ_0, repetimos el entrenamiento con $\alpha = 0.01$, $\alpha = 0.1$, $\alpha = 1$ y $\alpha = 2.5$

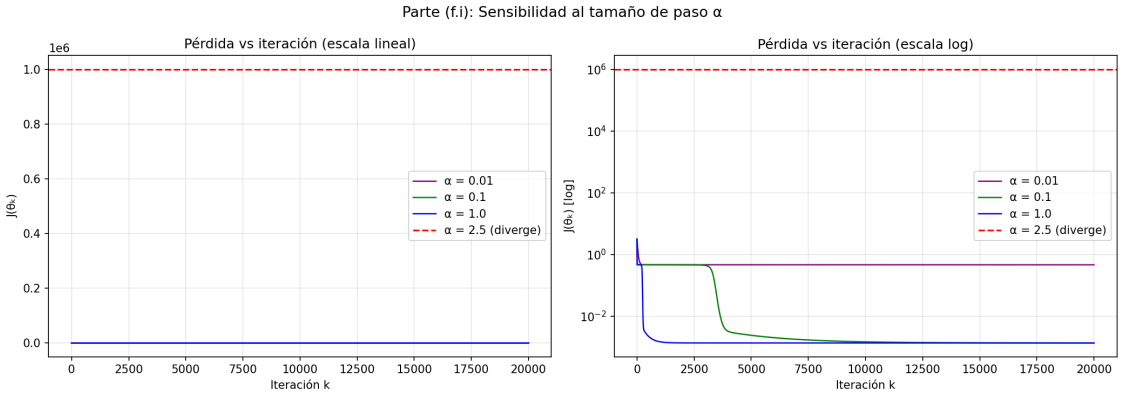


Figura 7: Pérdida $J(\theta_k)$ para distintos pasos α, en escala lineal (izquierda) y logarítmica (derecha). Con $\alpha = 2.5$ la pérdida diverge.

- $\alpha = 0.01$: $J_{\text{final}} \approx 0.459$, prácticamente en la meseta $\frac{1}{2}\text{Var}(y) = 0.4597$. En 20 000 iteraciones no logra salir de la meseta, de forma en que directamente no converge en el número de iteraciones dado.
- $\alpha = 0.1$: converge a $J_{\text{final}} \approx 0.00135$, un poco mas lento que $\alpha = 1$
- $\alpha = 1$: converge a $J_{\text{final}} \approx 0.00134$
- $\alpha = 2.5$: la pérdida se desborda a `NaN`. El paso supera el límite de estabilidad del descenso del gradiente para esta función, y los iterados crecen sin control.

Por lo tanto, un paso muy pequeño es estable pero demasiado lento, esto se vió cuando no se logró salir de la meseta en las 20.000 iteraciones, y un paso muy grande rompe la estabilidad y diverge; el valor intermedio $\alpha = 1$ es el que mejor equilibra ambas cosas.

ii. **Distintas inicializaciones.**

Repetimos el entrenamiento para $\alpha = 1$ para 10 inicializaciones con componentes en $[-1, 1]$ y otras 10 en $[-5, 5]$.

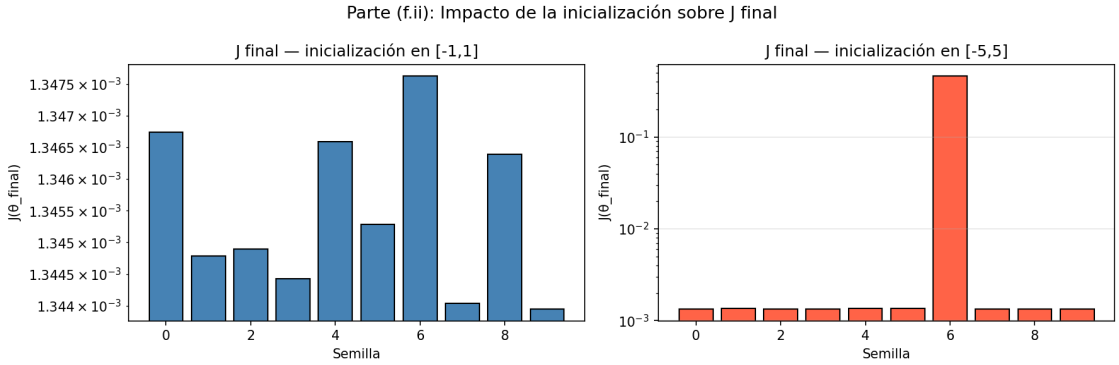


Figura 8: Pérdida final $J(\theta_{\text{final}})$ de 10 inicializaciones en $[-1, 1]$ (izquierda) y 10 en $[-5, 5]$ (derecha), con $\alpha = 1$, en escala logarítmica.

No siempre se alcanza el mismo valor final. Con $[-1, 1]$ las 10 corridas llegan a $J \approx 0.00134$–0.00135 (las diferencias en la cuarta cifra indican que 20 000 iteraciones no alcanzan el mínimo exacto). Con $[-5, 5]$, 9 de las 10 corridas llegan a $J \approx 0.00134$–0.00137, pero la semilla 6 se queda en $J \approx 0.4597$.

El valor de dicha semilla, es exactamente $\frac{1}{2}\text{Var}(y)$, la pérdida de la red que predice la media constante. En el θ final, la segunda neurona queda saturada: $z_2 \approx -7.7$ para todo x, de modo que $\sigma'(z_2) \approx 0.0004$. dado que $\sigma'(t) \to 0$ cuando $|t|$ es grande, los factores $\sigma'(z_2)$ que aparecen en el gradiente (vía $\delta_{2,i} = e_i v\, \sigma'(z_{2,i})$ y $\delta_{1,i} = \delta_{2,i}\, a_2\, \sigma'(z_{1,i})$) se vuelven minúsculos: el gradiente queda en $\approx 3 \times 10^{-5}$ y el descenso prácticamente no avanza, dejando $\hat{y} \approx c \approx \bar{y}$.

Con respecto al método, la saturación inicial por sí sola no basta para quedar atrapado; varias semillas de $[-5, 5]$ con $|z|$ grande también convergen. Lo que importa es si el entrenamiento llega a una región donde la sigmoide queda plana para todo x, porque es ahí en donde el gradiente deja de guiar el descenso, mosytrando que el descenso del gradiente no nos garantiza encontrar el mínimo global, solo garantiza acercarse a un punto crítico ($\nabla J = 0$), que podría ser una meseta de pérdida alta,

(g) Datos de otra función

i. **Entrenamiento.**

Entrenamos la misma red con los datos de $\tilde{f}$, partiendo del mismo θ_0 de (c), con $\alpha = 1$ y 20 000 iteraciones, y obtuvimos $J(\theta_g) = 0.0693$. La Figura 9 compara el ajuste de f (de (e)) con el de $\tilde{f}$.

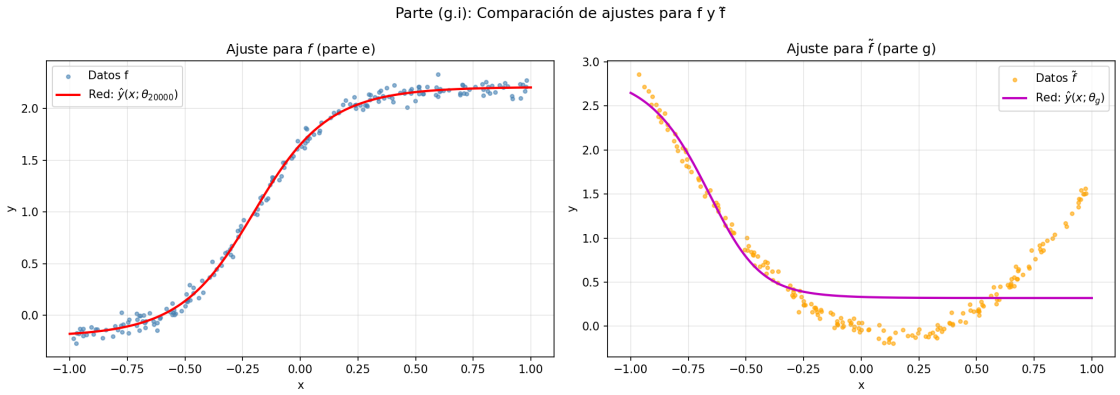


Figura 9: Ajuste de la red para f (izquierda, de (e)) y para $\tilde{f}$ (derecha). La curva de $\tilde{f}$ solo captura la rama decreciente.

La red no logra ajustar estos datos. La pérdida final $J(\theta_g) \approx 0.069$ es unas 50 veces mayor que la de f ($J \approx 0.0013$). En la figura, la curva ajustada es decreciente en todo $[-1, 1]$, mientras que los datos de $\tilde{f}$ bajan hasta $x \approx 0.1$ y luego vuelven a subir, formando una "V". La red solo captura la rama izquierda y aplana el resto.

ii. **Monotonía, cotas y por qué la red no puede aproximar $\tilde{f}$.**

Derivamos por regla de la cadena $\hat{y}(x;\theta) = c + v\,\sigma(z_2)$ respecto de x, siguiendo el camino $x \to z_1 \to h_1 \to z_2 \to h_2 \to \hat{y}$:

$$\frac{d\hat{y}}{dx} = v\,a_1\,a_2\,\sigma'(z_1)\,\sigma'(z_2).$$

Como $\sigma'(z_1)\,\sigma'(z_2) > 0$, el signo de $\dfrac{d\hat{y}}{dx}$ coincide con el de $v\,a_1\,a_2$, que no depende de x. Entonces $x \mapsto \hat{y}(x;\theta)$ es monótona en $\mathbb{R}$: creciente si $va_1a_2 > 0$, decreciente si $va_1a_2 < 0$, y constante solo en el caso degenerado $va_1a_2 = 0$.

Como $h_2 = \sigma(z_2) \in (0, 1)$, los valores de $\hat{y} = c + v\,h_2$ siempre están entre c y $c + v$: en $(c,\ c + v)$ si $v > 0$ y en $(c + v,\ c)$ si $v < 0$.

Los datos de $\tilde{f}$, en cambio, no son monótonos. Promediando $\tilde{y}$ por intervalos de x se ve que primero decrecen y luego crecen (forma de "V"):

Intervalo de x	Media de $\tilde{y}$
$[-1.00, -0.75)$	$+2.272$
$[-0.75, -0.50)$	$+1.372$
$[-0.50, -0.25)$	$+0.606$
$[-0.25,\ 0.00)$	$+0.101$
$[\,0.00,\ 0.25)$	-0.089
$[\,0.25,\ 0.50)$	$+0.015$
$[\,0.50,\ 0.75)$	$+0.429$
$[\,0.75,\ 1.00]$	$+1.193$

Tabla 3: Media de $\tilde{y}$ por intervalos de x: primero decrece y luego crece.

Como $\hat{y}(\cdot\,;\theta)$ es monótona para todo θ y $\tilde{f}$ no lo es, ninguna elección de parámetros puede seguir la "V": el mejor θ produce una curva decreciente que solo ajusta la rama izquierda ($J \approx 0.069$). Esta es una limitación estructural de la arquitectura (una neurona por capa), no del entrenamiento: ni α, ni el número de iteraciones, ni la inicialización cambian la conclusión.

Intervalo de x	Media de $\tilde{y}$
$[-1.00, -0.75)$	$+2.272$
$[-0.75, -0.50)$	$+1.372$
$[-0.50, -0.25)$	$+0.606$
$[-0.25,\ 0.00)$	$+0.101$
$[\ 0.00,\ 0.25)$	-0.089
$[\ 0.25,\ 0.50)$	$+0.015$
$[\ 0.50,\ 0.75)$	$+0.429$
$[\ 0.75,\ 1.00]$	$+1.193$

Tabla 4: Media de $\tilde{y}$ por intervalos de x: primero decrece y luego crece.

Se concluye que una función monótona no puede seguir una “V”. Por eso el mejor produce una curva decreciente que sólo ajusta la rama izquierda (J 0.069). Esta es una limitación estructural de la arquitectura (una neurona por capa), no del entrenamiento: ni , ni el número de iteraciones, ni la inicialización cambian la conclusión. Para representar ~ f haría falta más flexibilidad, por ejemplo más de una neurona en la primera capa.